

Санкт-Петербургский политехнический университет Петра Великого

Физико-механический институт

Кафедра прикладной математики и информатики

Математическая статистика

Отчет по лабораторной работе № 3

Выполнил студент гр. 5030102/30201

Жданов Дмитрий

Преподаватель

Баженов А.Н.

Санкт-Петербург

2026

1. Постановка задачи

Целью данной лабораторной работы является изучение метода визуализации распределений с помощью боксплота Тьюки и анализ выбросов в выборках различных распределений.

В ходе работы необходимо:

1. Сгенерировать выборки объемом $n=20$ и $n=100$ для следующих распределений:
 - нормального
 - распределения Коши
 - распределения Лапласа
 - распределения Пуассона
 - равномерного распределения
2. Для каждой выборки построить боксплот Тьюки.
3. Экспериментально определить долю выбросов:
 - для каждого распределения сгенерировать 1000 выборок заданного объема
 - для каждой выборки определить количество выбросов
 - вычислить долю выбросов как отношение числа выбросов к размеру выборки
 - найти среднюю долю выбросов по всем 1000 выборкам.

Основной задачей является анализ того, как тип распределения и размер выборки влияют на количество обнаруженных выбросов.

2. Теоретическая часть

Нормальное распределение: $N(x;0,1)$

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-a)^2}{2\sigma^2}}$$

Математическое ожидание (μ) = 0

Стандартное отклонение (σ) = 1

$$N(x; 0, 1) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}, \quad x \in \mathbb{R}$$

Распределение Коши: $C(x;0,1)$

$$f_X(x) = \frac{1}{\pi\gamma \left[1 + \left(\frac{x-x_0}{\gamma} \right)^2 \right]} = \frac{1}{\pi} \left[\frac{\gamma}{(x-x_0)^2 + \gamma^2} \right]$$

$x_0 \in \mathbb{R}$ — параметр сдвига;

$\gamma > 0$ — параметр масштаба.

$$C(x; 0, 1) = \frac{1}{\pi(1 + x^2)}, \quad x \in \mathbb{R}$$

Распределение Лапласа: $L(x, 0, 1/\sqrt{2})$

$$f(x) = \frac{\alpha}{2} e^{-\alpha|x-\beta|}, \quad -\infty < x < +\infty,$$

где $\alpha > 0$ — параметр масштаба, $-\infty < \beta < +\infty$ — параметр сдвига.

$$L\left(x; 0, \frac{1}{\sqrt{2}}\right) = \frac{1}{\sqrt{2}} e^{-\sqrt{2}|x|}, \quad x \in \mathbb{R}$$

Распределение Пуассона: $P(k, 10)$

$$p(k) \equiv \mathbb{P}(Y = k) = \frac{\lambda^k}{k!} e^{-\lambda},$$

где

- k — количество событий,
- λ — математическое ожидание случайной величины (среднее количество событий за фиксированный промежуток времени),

$$P(k; 10) = \frac{10^k e^{-10}}{k!}, \quad k = 0, 1, 2, \dots$$

Равномерное распределение: $U(x, -\sqrt{3}, \sqrt{3})$

$$f(x) = \begin{cases} 0, & \text{при } x \leq a \\ \frac{1}{b-a}, & \text{при } a < x \leq b \\ 0, & \text{при } x > b \end{cases}$$

a, b - границы интервалов

$$U\left(x; -\sqrt{3}, \sqrt{3}\right) = \begin{cases} \frac{1}{2\sqrt{3}}, & x \in [-\sqrt{3}, \sqrt{3}], \\ 0, & \text{иначе.} \end{cases}$$

Боксплот (boxplot), предложенный Джоном Тьюки, является графическим методом представления распределения данных. Он позволяет визуально оценить положение, разброс данных и наличие выбросов.

Основными элементами боксплота являются квартили и межквартильный размах.

Квартили делят упорядоченную выборку на четыре равные части:

- первый квартиль Q_1 - значение, ниже которого находится 25% данных;
- медиана Q_2 - значение, делящее выборку пополам;
- третий квартиль Q_3 - значение, ниже которого находится 75% данных.

Межквартильный размах определяется как:

$$IQR = Q_3 - Q_1$$

и характеризует разброс центральных 50% наблюдений.

В боксплоте центральный прямоугольник ограничен значениями Q_1 и Q_3 , а линия внутри него показывает медиану.

Для определения выбросов используется правило Тьюки. Вычисляются нижняя и верхняя границы:

$$X_1 = Q_1 - 1.5 \cdot IQR$$

$$X_2 = Q_3 + 1.5 \cdot IQR$$

Если наблюдение меньше X_1 или больше X_2 , оно считается выбросом.

Доля выбросов в выборке определяется как отношение числа выбросов к общему количеству элементов выборки:

$$\varepsilon = \frac{N_{outliers}}{n}$$

где

$N_{outliers}$ — количество выбросов,

n — объём выборки.

В данной работе используется метод моделирования. Для каждого распределения генерируется большое количество выборок, после чего вычисляется средняя доля выбросов:

$$\bar{\varepsilon} = \frac{1}{1000} \sum_{i=1}^{1000} \varepsilon_i$$

Такой подход позволяет получить экспериментальную оценку вероятности появления выбросов.

3. Реализация

Программа реализована на языке Python с использованием библиотек NumPy и Matplotlib.

На первом этапе реализована функция генерации выборок для каждого из рассматриваемых распределений. В зависимости от типа распределения вызывается соответствующая функция генерации случайных чисел.

Далее реализована функция поиска выбросов по правилу Тьюки. Внутри функции вычисляются первый и третий квартили выборки, затем определяется межквартильный размах. После этого вычисляются нижняя и верхняя границы допустимых значений. Все элементы выборки, выходящие за эти границы, считаются выбросами.

Для визуального анализа распределений строятся боксплоты Тьюки. Для каждого размера выборки формируются данные для всех распределений и отображаются на графике.

На следующем этапе проводится экспериментальное исследование доли выбросов. Для каждого распределения и каждого размера выборки выполняется 1000 генераций выборок. Для каждой выборки определяется количество выбросов и вычисляется их доля. Полученные значения сохраняются, после чего вычисляется среднее значение доли выбросов.

Результаты выводятся в консоль в виде средней доли выбросов для каждого распределения и каждого размера выборки.

4. Результаты

normal n= 20 средняя доля выбросов = 0.021900000000000003

normal n= 100 средняя доля выбросов = 0.0092

cauchy n= 20 средняя доля выбросов = 0.15230000000000002

cauchy n= 100 средняя доля выбросов = 0.155

laplace n= 20 средняя доля выбросов = 0.07659999999999999


laplace n= 100 средняя доля выбросов = 0.06448000000000001


poisson n= 20 средняя доля выбросов = 0.02485

poisson n= 100 средняя доля выбросов = 0.01002

uniform n= 20 средняя доля выбросов = 0.00185

uniform n= 100 средняя доля выбросов = 0.0





5. Обсуждение

В результате выполнения программы были построены боксплоты Тьюки для всех исследуемых распределений при объёмах выборки $n=20$ и $n=100$.

По построенным графикам можно наблюдать различия в форме распределений и количестве выбросов.

Результаты вычисления средней доли выбросов показали следующие особенности:

- для нормального распределения наблюдается небольшая доля выбросов, доля выбросов уменьшается с увеличением выборки;
- распределение Коши демонстрирует наибольшее количество выбросов из-за тяжёлых хвостов, доля выбросов практически не меняется с увеличением выборки;
- распределение Лапласа имеет больше выбросов, чем нормальное распределение и доля выбросов немного уменьшается с увеличением выборки;
- для распределения Пуассона наблюдается небольшая доля выбросов, доля выбросов уменьшается с увеличением выборки;
- для равномерного распределения выбросы практически отсутствуют и при увеличении выборки их доля быстро стремится к нулю;

6. Выводы

Экспериментальные результаты показали, что доля выбросов существенно зависит от типа распределения. Распределения с тяжёлыми хвостами, такие как распределение Коши, демонстрируют значительно большую долю выбросов по сравнению с распределениями с ограниченной областью значений, например равномерным распределением.

Особенно заметно, что для распределения Коши доля выбросов практически не изменяется при увеличении объёма выборки. Это объясняется тем, что распределение Коши обладает очень тяжёлыми хвостами и не имеет конечных математического ожидания и дисперсии. В результате вероятность появления экстремальных значений остаётся высокой независимо от размера выборки, поэтому правило Тьюки продолжает выделять примерно одинаковую долю наблюдений как выбросы.

Для распределения Пуассона также наблюдается уменьшение доли выбросов при увеличении размера выборки, однако это уменьшение выражено слабее, чем у непрерывных распределений. Это связано с дискретной природой распределения и его асимметрией, из-за чего границы выбросов, определяемые по правилу Тьюки, работают менее гибко и часть значений может переходить в категорию выбросов скачкообразно.

Таким образом, проведённый эксперимент показал, что поведение выбросов зависит не только от размера выборки, но и от свойств самого распределения.

7. Список литературы

1. Боровков А.А. Математическая статистика
2. Кобзарь А.И. Прикладная математическая статистика.
3. Нормальное распределение // Википедия : свободная энциклопедия. — URL: https://ru.wikipedia.org/wiki/Нормальное_распределение
4. Распределение Коши // Википедия : свободная энциклопедия. — URL: https://ru.wikipedia.org/wiki/Распределение_Коши
5. Распределение Лапласа // Википедия : свободная энциклопедия. — URL: https://ru.wikipedia.org/wiki/Распределение_Лапласа
6. Распределение Пуассона // Википедия : свободная энциклопедия. — URL: https://ru.wikipedia.org/wiki/Распределение_Пуассона