

Санкт-Петербургский политехнический университет Петра Великого

Физико-механический институт

Кафедра прикладной математики и информатики

Математическая статистика

Отчет по лабораторной работе № 4

Выполнил студент гр. 5030102/30201

Жданов Дмитрий

Преподаватель

Баженов А.Н.

Санкт-Петербург

2026

1. Постановка задачи

Целью работы является изучение основных методов описательной статистики, используемых для анализа распределений случайных величин. В ходе работы исследуется поведение выборок различного объёма и их связь с теоретическими распределениями.

В рамках лабораторной работы рассматриваются следующие распределения:

- нормальное распределение
- распределение Коши
- распределение Лапласа
- распределение Пуассона
- равномерное распределение

Для каждого распределения были сгенерированы выборки объёма:

$$n=20,60,100$$

Для полученных выборок были выполнены следующие действия:

1. Построены эмпирические функции распределения и соответствующие теоретические функции распределения.
2. Построены гистограммы и ядерные оценки плотности с использованием гауссова ядра.
3. Полученные оценки плотности были сравнены с теоретическими плотностями распределений.

Для непрерывных распределений графики строились на интервале:

$$[-4,4]$$

Для распределения Пуассона - на интервале:

$$[6,14]$$

Основной задачей работы является исследование влияния объёма выборки на приближение эмпирических характеристик к теоретическим, а также сравнение различных способов оценки плотности распределения.

2. Теоретическая часть

Нормальное распределение: $N(x;0,1)$

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-a)^2}{2\sigma^2}}$$

Математическое ожидание (μ) = 0

Стандартное отклонение (σ) = 1

$$N(x; 0, 1) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}, \quad x \in \mathbb{R}$$

Распределение Коши: C(x;0,1)

$$f_X(x) = \frac{1}{\pi\gamma \left[1 + \left(\frac{x-x_0}{\gamma}\right)^2\right]} = \frac{1}{\pi} \left[\frac{\gamma}{(x-x_0)^2 + \gamma^2} \right]$$

$x_0 \in \mathbb{R}$ — параметр сдвига;

$\gamma > 0$ — параметр масштаба.

$$C(x; 0, 1) = \frac{1}{\pi(1 + x^2)}, \quad x \in \mathbb{R}$$

Распределение Лапласа: L(x, 0, 1/sqrt(2))

$$f(x) = \frac{\alpha}{2} e^{-\alpha|x-\beta|}, \quad -\infty < x < +\infty,$$

где $\alpha > 0$ — параметр масштаба, $-\infty < \beta < +\infty$ — параметр сдвига.

$$L\left(x; 0, \frac{1}{\sqrt{2}}\right) = \frac{1}{\sqrt{2}} e^{-\sqrt{2}|x|}, \quad x \in \mathbb{R}$$

Распределение Пуассона: P(k, 10)

$$p(k) \equiv \mathbb{P}(Y = k) = \frac{\lambda^k}{k!} e^{-\lambda},$$

где

- k — количество событий,
- λ — математическое ожидание случайной величины (среднее количество событий за фиксированный промежуток времени),

$$P(k; 10) = \frac{10^k e^{-10}}{k!}, \quad k = 0, 1, 2, \dots$$

Равномерное распределение: U(x, -sqrt(3), sqrt(3))

$$f(x) = \begin{cases} 0, & \text{при } x \leq a \\ \frac{1}{b-a}, & \text{при } a < x \leq b \\ 0, & \text{при } x > b \end{cases}$$

a, b - границы интервалов

$$U(x; -\sqrt{3}, \sqrt{3}) = \begin{cases} \frac{1}{2\sqrt{3}}, & x \in [-\sqrt{3}, \sqrt{3}], \\ 0, & \text{иначе.} \end{cases}$$

Эмпирическая функция распределения

Эмпирическая функция распределения является непараметрической оценкой функции распределения случайной величины на основе выборочных данных.

Пусть имеется выборка

$$X_1, X_2, \dots, X_n$$

Тогда эмпирическая функция распределения определяется следующим образом:

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n I(X_i \leq x)$$

Где $I(\cdot)$ — индикаторная функция.

Эмпирическая функция распределения показывает долю наблюдений, значения которых меньше или равны заданному значению x .

График данной функции имеет ступенчатый вид. Каждый скачок функции соответствует одному наблюдению выборки, а величина скачка равна $1/n$.

Согласно теореме Гливенко — Кантелли, при увеличении объема выборки эмпирическая функция распределения сходится к истинной функции распределения случайной величины.

Таким образом, при достаточно больших объемах выборки эмпирическая функция распределения является хорошей оценкой теоретической функции распределения.

Оценка плотности распределения

Для непрерывных распределений важной характеристикой является функция плотности вероятности. Однако в большинстве практических задач истинная плотность распределения неизвестна, поэтому её необходимо оценивать по выборочным данным.

Одним из простейших способов оценки плотности является построение гистограммы. При этом диапазон значений случайной величины разбивается на интервалы, и для каждого интервала вычисляется относительная частота попадания наблюдений. Полученная функция имеет ступенчатый вид.

Недостатком гистограммы является её зависимость от числа и ширины интервалов, а также отсутствие гладкости.

Ядерная оценка плотности

Более гибким методом оценки плотности является ядерная оценка плотности (Kernel Density Estimation).

Суть метода заключается в том, что каждое наблюдение выборки заменяется некоторой гладкой функцией — ядром. Чаще всего используется гауссово ядро. Далее значения этих функций суммируются, образуя итоговую оценку плотности распределения.

Математически ядерная оценка плотности определяется формулой:

$$\hat{f}(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - X_i}{h}\right)$$

где

- K — функция ядра
- h — параметр сглаживания (ширина окна)
- n — размер выборки

Ядерная оценка плотности позволяет получить гладкую функцию, которая лучше приближает истинную плотность распределения по сравнению с гистограммой.

Дискретные распределения

Для дискретных случайных величин вместо функции плотности используется функция вероятности (Probability Mass Function, PMF).

Она задаёт вероятность того, что случайная величина принимает конкретное значение:

$$P(X = k)$$

В работе для распределения Пуассона использовалась теоретическая функция вероятности, вычисляемая по формуле:

$$P(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}$$

Формула Сильвермана (Silverman's rule of thumb) — это стандартный способ выбрать ширину окна h (bandwidth) для ядерной оценки плотности (KDE).

Она выглядит так:

$$h = 0.9 \cdot \min\left(\sigma, \frac{IQR}{1.34}\right) \cdot n^{-1/5}$$

где:

- σ — стандартное отклонение выборки
- IQR — межквартильный размах ($Q3 - Q1$)
- n — размер выборки

Формула Сильвермана даёт асимптотически оптимальную ширину при предположении нормальности распределения.

В данной работе рассматриваются распределения с различными свойствами (включая тяжёлые хвосты у Коши), поэтому вместо фиксированного значения используется набор из трех ширин.

Это позволяет проанализировать влияние параметра сглаживания и визуально оценить устойчивость ядерной оценки плотности.

3.Реализация

Для выполнения лабораторной работы использовался язык программирования Python и библиотеки NumPy, SciPy, Matplotlib и Seaborn.

Сначала для каждого распределения генерировались случайные выборки заданных размеров. Для этого использовались функции генерации случайных величин из библиотеки SciPy.

Для каждой выборки вычислялась эмпирическая функция распределения. Для её построения значения выборки сортировались, после чего для каждого значения определялась доля элементов выборки, не превышающих данное значение.

Далее строились графики, на которых одновременно отображались:

- эмпирическая функция распределения
- теоретическая функция распределения

Это позволило визуально сравнить полученную выборочную оценку с истинной функцией распределения.



После этого выполнялась оценка плотности распределения. Для этого строились:



- гистограмма выборки
- ядерная оценка плотности с использованием гауссова ядра
- теоретическая плотность распределения

Полученные графики позволяли сравнить различные способы оценки плотности распределения и оценить степень их приближения к теоретической плотности.


Для распределения Пуассона, являющегося дискретным, вместо плотности вероятности использовалась функция вероятности (PMF), задающая вероятность конкретных значений случайной величины.

4. Результаты







Нормальное распределение, объем выборки = 100




Нормальное распределение, объем выборки = 100




Распределение Коши, объем выборки = 20




Распределение Коши, объем выборки = 20




Распределение Коши, объем выборки = 60




Распределение Коши, объем выборки = 60




Распределение Коши, объем выборки = 100




Распределение Коши, объем выборки = 100




Распределение Лапласа, объем выборки = 20




Распределение Лапласа, объем выборки = 20




Распределение Лапласа, объем выборки = 60




Распределение Лапласа, объем выборки = 60




Распределение Лапласа, объем выборки = 100




Распределение Лапласа, объем выборки = 100




Равномерное распределение, объем выборки = 20




Равномерное распределение, объем выборки = 20




Равномерное распределение, объем выборки = 60




Равномерное распределение, объем выборки = 60







Равномерное распределение, объем выборки = 100





Равномерное распределение, объем выборки = 100









5. Обсуждение

В результате выполнения лабораторной работы были построены графики теоретических функций распределения, эмпирических функций распределения и функций распределения, полученных по гистограмме, для всех исследуемых распределений при различных объемах выборки. Все графики строились на одинаковых интервалах, что позволило корректно сравнивать теоретические и эмпирические оценки. Эмпирическая функция распределения была дополнительно достроена до значений 0 и 1 на концах интервала, что соответствует её теоретическому определению.

Анализ полученных графиков показывает, что при увеличении объема выборки эмпирическая функция распределения всё точнее приближает теоретическую функцию распределения. Это соответствует

теореме Гливенко–Кантелли, согласно которой эмпирическая функция распределения сходится к истинной функции распределения при увеличении числа наблюдений.

Также была построена функция распределения, полученная по гистограмме как кумулятивная сумма значений гистограммы. Данная оценка приближает теоретическую функцию распределения хуже, чем эмпирическая функция распределения, особенно при малых объёмах выборки, однако с ростом числа наблюдений её точность увеличивается.

Для каждой выборки были построены гистограммы и ядерные оценки плотности вероятности. Ядерная оценка плотности вычислялась с использованием гауссового ядра и различных значений параметра ширины окна h . В ядерной оценке плотность представляется как сумма нормальных функций, построенных в каждой точке выборки, а параметр h определяет ширину этих функций и степень сглаживания.

При малых значениях h оценка плотности получается сильно изрезанной и чувствительной к случайным колебаниям выборки. При больших значениях h происходит чрезмерное сглаживание, в результате чего теряются особенности распределения. При промежуточных значениях параметра h достигается наилучшее приближение к теоретической плотности вероятности.

Сравнение гистограммы и ядерной оценки плотности показывает, что гистограмма имеет ступенчатый вид и существенно зависит от выбора числа интервалов, тогда как ядерная оценка позволяет получить более гладкую и устойчивую аппроксимацию плотности распределения.

Для распределения Пуассона дополнительно были построены графики функции вероятности и функции распределения. Полученные графики демонстрируют дискретную природу данного распределения. Эмпирическая функция распределения и функция распределения, полученная по гистограмме, с увеличением объёма выборки всё точнее приближают теоретическую функцию распределения, а гистограмма приближает теоретическую функцию вероятности.

В результате обсуждения на паре были исправлены некоторые гистограммы (ранее имели дырки), добавлена функция распределения по гистограмме.

6. Выводы

В ходе выполнения лабораторной работы было показано, что эмпирическая функция распределения является состоятельной оценкой теоретической функции распределения. При увеличении объёма выборки её график всё точнее совпадает с графиком истинной функции распределения, что согласуется с теоремой Гливенко–Кантелли. Дополнительное построение функции распределения по гистограмме показало, что данная оценка также сходится к теоретической функции распределения, однако при малых объёмах выборки она менее точна по сравнению с эмпирической функцией распределения.

Было проведено сравнение различных способов оценки плотности распределения: гистограммы и ядерной оценки плотности. Установлено, что гистограмма имеет ступенчатый вид и существенно зависит от выбора числа интервалов разбиения, тогда как ядерная оценка плотности позволяет получить более гладкую аппроксимацию распределения. При этом качество ядерной оценки зависит от параметра ширины окна h , который определяет степень сглаживания. При малых значениях h оценка становится слишком чувствительной к случайным колебаниям выборки, при больших значениях происходит чрезмерное сглаживание, а при промежуточных значениях достигается наилучшее приближение к теоретической плотности.

Для дискретного распределения Пуассона были построены функции вероятности и функции распределения, что позволило продемонстрировать отличие дискретного случая от непрерывного. При увеличении объёма выборки эмпирические оценки также сходятся к теоретическим значениям.

Таким образом, увеличение объёма выборки приводит к улучшению приближения эмпирических характеристик к теоретическим, а использование ядерных методов позволяет получать более точные и наглядные оценки плотности распределения по сравнению с гистограммами.

7. Список литературы

1. Боровков А.А. Математическая статистика
2. Кобзарь А.И. Прикладная математическая статистика.
3. Нормальное распределение // Википедия : свободная энциклопедия. — URL: https://ru.wikipedia.org/wiki/Нормальное_распределение
4. Распределение Коши // Википедия : свободная энциклопедия. — URL: https://ru.wikipedia.org/wiki/Распределение_Коши
5. Распределение Лапласа // Википедия : свободная энциклопедия. — URL: https://ru.wikipedia.org/wiki/Распределение_Лапласа
6. Распределение Пуассона // Википедия : свободная энциклопедия. — URL: https://ru.wikipedia.org/wiki/Распределение_Пуассона