

Санкт-Петербургский политехнический университет Петра Великого

Физико-механический институт

Кафедра прикладной математики и информатики

Математическая статистика

Отчет по лабораторной работе № 6

Выполнил студент гр. 5030102/30201

Жданов Дмитрий

Преподаватель

Баженов А.Н.

Санкт-Петербург

2026

1. Постановка задачи

Цель работы: сравнить устойчивость двух методов оценивания параметров линейной регрессии - метода наименьших квадратов (МНК) и метода наименьших модулей (МНМ) - при наличии выбросов.

Задачи:

- Сгенерировать x_i равномерно на отрезке $[-1.8; 2]$ с шагом 0.2 (20 точек).
- Сгенерировать $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$, где $\beta_0 = 2$, $\beta_1 = 2$, $\varepsilon_i \sim N(0, 1)$.
- Оценить параметры модели $y = \beta_0 + \beta_1 x$ двумя методами: МНК и МНМ (робастная версия по методичке).
- Повторить пункты 1–3, добавив выбросы: $y_1 \leftarrow y_1 + 10$, $y_{20} \leftarrow y_{20} - 10$.
- Построить графики регрессионных прямых и исходных данных с одинаковыми границами по осям для наглядности.
- Вычислить абсолютные и относительные погрешности оценок параметров.
- Сравнить результаты и сделать выводы об устойчивости методов.

2. Теоретическая часть

Модель простой линейной регрессии

Регрессионная модель описания данных называется **простой линейной регрессией**, если

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \quad i = 1, \dots, n,$$

где $x_1, \dots, x_n$ — заданные числа (значения фактора); $y_1, \dots, y_n$ — наблюдаемые значения отклика; $\varepsilon_1, \dots, \varepsilon_n$ — независимые, нормально распределённые $N(0, \sigma)$ случайные величины (ненаблюдаемые); β_0, β_1 — неизвестные параметры, подлежащие оцениванию.

Метод наименьших квадратов (МНК)

МНК минимизирует сумму квадратов остатков, т.е. квадрат L_2 -нормы:

$$Q(\beta_0, \beta_1) = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2 \rightarrow \min_{\beta_0, \beta_1}.$$

Для нахождения минимума приравняем частные производные к нулю:

$$\frac{\partial Q}{\partial \beta_0} = -2 \sum (y_i - \beta_0 - \beta_1 x_i) = 0, \quad \frac{\partial Q}{\partial \beta_1} = -2 \sum x_i (y_i - \beta_0 - \beta_1 x_i) = 0.$$

Получаем систему нормальных уравнений:

$$\sum y_i = n\beta_0 + \beta_1 \sum x_i, \quad \sum x_i y_i = \beta_0 \sum x_i + \beta_1 \sum x_i^2.$$

Вводя выборочные средние $\bar{x} = \frac{1}{n} \sum x_i$, $\bar{y} = \frac{1}{n} \sum y_i$, $\overline{x^2} = \frac{1}{n} \sum x_i^2$, $\overline{xy} = \frac{1}{n} \sum x_i y_i$, получаем:

$$\hat{\beta}_1 = \frac{\overline{xy} - \bar{x}\bar{y}}{\overline{x^2} - (\bar{x})^2}, \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}.$$

МНК-оценки оптимальны при нормальном распределении ошибок, но чувствительны к выбросам.

Метод наименьших модулей (МНМ)

МНМ минимизирует сумму абсолютных отклонений (L_1 -норму):

$$L(\beta_0, \beta_1) = \sum_{i=1}^n |y_i - \beta_0 - \beta_1 x_i| \rightarrow \min.$$

Аналитического решения не существует, однако можно построить робастные оценки, заменив в формулах МНК выборочные средние на медианы, а среднеквадратические отклонения – на интерквартильные широты, а также используя знаковый коэффициент корреляции (квадрантный). Робастные оценки $\hat{\beta}_{1R}$ и $\hat{\beta}_{0R}$ вычисляются по формулам:

$$\hat{\beta}_{1R} = r_Q \frac{q_y^*}{q_x^*}, \quad \hat{\beta}_{0R} = \text{med } y - \hat{\beta}_{1R} \text{med } x,$$

где q_x^* и q_y^* – нормированные интерквартильные широты, а r_Q – квадрантный (знаковый) коэффициент корреляции:

$$r_Q = \frac{1}{n} \sum_{i=1}^n \text{sgn}(x_i - \text{med } x) \text{sgn}(y_i - \text{med } y),$$

$$\text{sgn } z = \begin{cases} 1, & z > 0, \\ 0, & z = 0, \\ -1, & z < 0. \end{cases}$$

Интерквартильные широты (размахи) определяются через порядковые статистики:

$$q_x^* = \frac{x_{(j)} - x_{(l)}}{k_q(n)}, \quad q_y^* = \frac{y_{(j)} - y_{(l)}}{k_q(n)},$$

где $x_{(l)}$ – нижний квартиль, $x_{(j)}$ – верхний квартиль, а l и j – их номера в упорядоченной выборке. Номера квартилей находятся по правилу:

$$l = \begin{cases} [n/4] + 1, & n/4 \text{ дробное,} \\ n/4, & n/4 \text{ целое,} \end{cases} \quad j = n - l + 1.$$

Например, при $n = 20$: $n/4 = 5$ – целое, поэтому $l = 5$, $j = 20 - 5 + 1 = 16$. То есть нижним квартилем является 5-й по порядку элемент выборки, а верхним – 16-й. Разность $x_{(j)} - x_{(l)}$ даёт межквартильный размах (IQR). Параметр $k_q(n)$ – нормировочный коэффициент, зависящий от объёма выборки; он выбирается так, чтобы оценка была состоятельной. Для нормального распределения $k_q(n) \approx 1.34$. В работе принимается $k_q(n) = 1.34$ для всех n . Такая процедура обеспечивает устойчивость оценок к выбросам, поскольку медианы и квартили малочувствительны к аномальным наблюдениям, а знаковая функция учитывает только направление отклонения.

Абсолютная и относительная погрешности

Абсолютная погрешность оценки параметра:

$$\Delta\beta_0 = \hat{\beta}_0 - \beta_0, \quad \Delta\beta_1 = \hat{\beta}_1 - \beta_1.$$

Относительная погрешность:

$$\delta\beta_0 = \frac{|\Delta\beta_0|}{|\beta_0|} \cdot 100\%, \quad \delta\beta_1 = \frac{|\Delta\beta_1|}{|\beta_1|} \cdot 100\%.$$

3.Реализация


- numpy – генерация данных и вычисления;
- matplotlib.pyplot – построение графиков.

Алгоритм программы:

1. Генерация x_i с шагом 0.2 на $[-1.8; 2]$.
2. Генерация ошибок $\varepsilon_i \sim N(0, 1)$ и вычисление y_i
3. Расчёт МНК-оценок по аналитическим формулам через средние.
4. Расчёт робастных МНМ-оценок по формулам (через медианы, квартили и знаковый коэффициент).
5. Повторение с добавлением выбросов (изменение первого и последнего y).
6. Вычисление погрешностей и построение графиков с одинаковыми пределами по осям для обоих подграфиков.

4. Результаты

На рисунке показаны диаграммы рассеяния и регрессионные прямые для двух случаев. Границы по осям установлены одинаковыми, чтобы обеспечить корректное визуальное сравнение. В таблице приведены оценки параметров и их погрешности.



Диаграммы рассеяния и линии регрессии (МНК – красный пунктир, МНМ – зелёный пунктир, истинная прямая – чёрная сплошная). Оси имеют одинаковый масштаб на обоих графиках.

Результаты в виде таблицы:

Метод	β_0	$\Delta\beta_0$	$\delta\beta_0, \%$	β_1	$\Delta\beta_1$	$\delta\beta_1, \%$
МНК	1.878	-0.122	6.08	1.502	-0.498	24.89
МНМ	2.022	0.022	1.12	0.988	-1.012	50.62
МНК (выбросы)	2.021	0.021	1.07	0.074	-1.926	96.32
МНМ (выбросы)	2.055	0.055	2.77	0.658	-1.342	67.08

5. Обсуждение

Без выбросов

В отсутствие аномальных наблюдений метод наименьших квадратов (МНК) дал оценки

$\beta_0 = 1.8785$ и $\beta_1 = 1.5022$. Относительные ошибки составили 6.08% для β_0 и 24.89% для β_1 .

Метод наименьших модулей (МНМ) показал $\beta_0 = 2.0225$ и $\beta_1 = 0.9876$. При этом ошибка для свободного члена оказалась очень малой (1.12%), однако для наклона β_1 она существенно выше — 50.62%.

Это объясняется тем, что при малом объёме выборки ($n = 20$) и наличии случайного шума оценки наклона оказываются более нестабильными. Кроме того, робастная природа МНМ, основанная на медианных характеристиках, приводит к потере части информации о наклоне прямой.

С выбросами

После добавления двух сильных выбросов (увеличение первой точки на +10 и уменьшение последней на -10) МНК дал значительное искажение оценки наклона:

β_1 снизился до 0.0736, что при истинном значении 2 соответствует ошибке 96.32%. Свободный член при этом оценился как $\beta_0 = 2.0213$ с небольшой ошибкой 1.07%.

Это демонстрирует крайне высокую чувствительность МНК к выбросам, особенно в оценке углового коэффициента.

Метод МНМ также изменил оценки, но менее резко: $\beta_1 = 0.6584$ (ошибка 67.08%), $\beta_0 = 2.0554$ (ошибка 2.77%). Несмотря на заметное смещение наклона, результат остаётся существенно ближе к истинному значению, чем у МНК.

Визуализация

На графиках с одинаковыми границами осей видно, что МНК сильно «подстраивается» под выбросы: после их добавления его прямая становится почти горизонтальной ($\beta_1 \approx 0.07$).

МНМ также реагирует на аномальные точки, однако сохраняет более выраженный наклон и в целом лучше отражает общую тенденцию данных.

6. Выводы

Полученные результаты показывают, что метод наименьших квадратов существенно более чувствителен к выбросам, особенно при оценке коэффициента наклона. Метод наименьших модулей демонстрирует большую устойчивость: при наличии аномальных наблюдений его оценки изменяются менее резко, хотя и могут быть смещёнными.

7. Список литературы

1. С.А. Бабахина, А.Н. Баженов ПРАКТИКУМ ПО МАТЕМАТИЧЕСКОЙ СТАТИСТИКЕ
2. Боровков А.А. Математическая статистика
3. Кобзарь А.И. Прикладная математическая статистика.